

盘古气象大模型轻量化与推理优化说明

队伍：侍奉部

模型：pgw_lite_pruned_96 / model_fp16_alias_compact.pth

1. 概述

本方案以组委会盘古气象模型为教师，通过结构化剪枝、全 69 通道知识蒸馏、FP16/INT8 混合精度存储、别名权重无损压缩和 gfx936 HIP 注意力内核优化，同时降低模型文件、显存与前向时延。学生模型直接预测全部 69 个气象通道，不使用外置仿射或全局均值修正。

2. 设计思路

轻量化必须同时保持精度和可复现性。因此不搜索多个运行时模型分支，而是锁定一个全深度 pruned_96 结构：patch=[2,8,8]，embed_dim=96，num_heads=[3,6,6,3]，depth=[2,6,6,2]，window=[2,6,12]。结构化剪枝保留完整注意力头和一致残差通道；蒸馏用教师输出与中间特征补偿容量下降；之后才进行存储压缩和无损运行时优化。

3. 模型轻量化方法

① 宽度剪枝：从 embed_dim=192 降至 96，完整移除低重要性注意力头与关联通道。② 空间 patch 从 4×4 放大到 8×8，降低 token 数和注意力开销。③ 全 69 通道蒸馏损失由真值 L1、教师 L1 和 layer1/layer2 特征损失构成，权重为 0.3/0.5/0.2。④ 量化时保留最敏感的 5 个 Linear 权重为 FP16，其余 62 个 Linear 权重按输出通道 INT8 存储。⑤ 删除 224 组 OneFuser 重复别名，加载时由同一运行时模块恢复，不改变权重值。

4. 性能优化与实现

检查点加载采用逐 tensor 反量化，避免同时保留整份 INT8 和 FP16 state_dict；相同的位置索引和 mask 缓冲区在加载后共享存储；原始 checkpoint 在模型就绪后立即释放。这些优化只改变存储生命周期，不改变模型数学输出。

推理中的 EarthAttention 用仓库内 HIP 源码实现 full-row-fast 路径，固定 score stride=144、QK tile=16，进一步使用直接 score store 和 PV 双缓冲减少 LDS 往返与同步。原始 packed bias 在转换完成后释放，减少重复常驻显存。HIP 共享库在首次推理时根据源码和参数指纹编译并缓存，无需携带闭源二进制。

5. 实验结果与分析

历史 DCU 实测中，同一 pruned_96 模型的 P2 关/开稳态平均时延为 100.2613/78.0757 ms，平均降低 22.13%，四个 69 通道输出逐位一致。缓冲区共享将峰值/常驻分配从 574.5/179.8 MiB 降至 483.5/88.8 MiB；进一步释放原始 bias 回收约 21.4 MiB，且输出不变。

平台历史记录的最高总分为 90.8210（轻量化 36.6004、推理 18.0006、预测 36.2200）；比 90.7455 版本提高 0.0755，预测分保持不变。该分数是平台实测记录，不代替对当前 ZIP 和模型哈希的重新审计；每次提交仍需保存实际产物哈希和平台回执。

结果表明：结构化剪枝和蒸馏主要决定预测能力；混合精度与别名压缩主要减少文件体积；缓冲区共享和 bias 释放改善显存；HIP P2 内核主要提升速度。分层实现便于逐项做输出一致性和回退验证。

6. 程序代码模块说明

distill_train.py：固定 pruned_96 的蒸馏、验证、断点与 FP16 导出。

pangu_profile_model.py：按 profile 构建模型。

scripts/prune_structured.py：从教师权重生成结构化学生初始化。

scripts/convert_fp16.py：保留别名关系的 FP16 转换。

scripts/analyze_quant_sensitivity.py 与 quantize_mixed_precision.py：敏感度排序与混合精度存储。

scripts/compact_fuser_alias_checkpoint.py：无损删除 OneFuser 重复权重。

inference.py、p2_tiled_attention.py、hip_earth_attention_tiled.py：检查点加载、P2 替换和 HIP 动态编译。

scripts/build_submission.sh 与 audit_submission_package.py：提交包生成与精确白名单审计。

7. 详细程序代码编译说明

基础环境使用竞赛服务器预置的 Python、PyTorch/DTK、Apex 和 OneScience，不需要重新安装依赖。检查 Python 文件可执行：

```
python -m py_compile distill_train.py inference.py pangu_profile_model.py
```

仓库内唯一需要编译的部分是 HIP EarthAttention。默认编译器为 /opt/dtk/bin/hipcc；运行 inference.py 时会自动执行并缓存带指纹的 .so：

```
/opt/dtk/bin/hipcc -O3 -std=c++17 -fPIC --shared -DPANGU_FULL_ROW_SCORE_STRIDE=144  
-DPANGU_FULL_ROW_QK_TILE=16 hip_kernels/earth_attention_tiled_fwd.hip -Wl,-rpath,/opt/dtk/lib -o  
<fingerprint>.so
```

共享库默认位于 logs/hip_earth_attention_tiled_build/。需确保 hipcc 和 /opt/dtk/lib 存在、logs/ 可写。如平台要求临时目录，可设置 PANGU_TILED_HIP_BUILD_DIR=/tmp/pangu_hip_build；无需将 .so 加入提交包。

8. 详细代码运行使用说明

以下命令均在 pangu_weather/ 目录执行。将组委会权重放到 data/checkpoints/model_bak.pth，然后生成 pruned_96 初始化：

```
python scripts/convert_fp16.py --source data/checkpoints/model_bak.pth --output  
data/checkpoints/model_teacher_fp16.pth  
python scripts/prune_structured.py --source data/checkpoints/model_teacher_fp16.pth --output  
data/checkpoints/model_pgw_lite_pruned_96.pth --target-profile pgw_lite_pruned_96 --dtype fp16
```

运行蒸馏。脚本自动从 latest/train 检查点续训，否则从上述剪枝初始化开始：

```
python distill_train.py
```

最优模型输出为 data/checkpoints/model_pgw_lite_pruned_96_fp16.pth。然后进行 FP16 规整、敏感度分析、混合精度存储和别名压缩：

```
python scripts/convert_fp16.py --source data/checkpoints/model_pgw_lite_pruned_96_fp16.pth  
--output data/checkpoints/model_pgw_lite_pruned_96_converted_fp16.pth  
python scripts/analyze_quant_sensitivity.py --checkpoint  
data/checkpoints/model_pgw_lite_pruned_96_converted_fp16.pth  
python scripts/quantize_mixed_precision.py --checkpoint  
data/checkpoints/model_pgw_lite_pruned_96_converted_fp16.pth --output  
data/checkpoints/model_fp16.pth  
python scripts/compact_fuser_alias_checkpoint.py --source data/checkpoints/model_fp16.pth  
--output data/checkpoints/model_fp16_alias_compact.pth
```

9. 推理、评估与提交

检查 conf/config.yaml 中的 data_dir、stats_dir、static_dir 和 test_ratio，然后直接指定最终检查点。首次执行会自动编译 HIP 内核：

```
PANGU_CHECKPOINT=model_fp16_alias_compact.pth python inference.py  
python result.py
```

推理预测写入 result/output/，评估生成 result/rmse.npy 和 result/acc.npy。启动日志应显示 profile=pgw_lite_pruned_96，检查点不应出现非有限 tensor。

模型 ZIP 必须只在根目录包含 model_fp16.pth：

```
mkdir -p /tmp/pangu_model  
cp data/checkpoints/model_fp16_alias_compact.pth /tmp/pangu_model/model_fp16.pth  
(cd /tmp/pangu_model && zip -9 ../model.zip model_fp16.pth)
```

代码包使用一键脚本生成。脚本同时复制蒸馏 Markdown 和本 PDF，修改评测路径并执行精确白名单审计：

```
bash scripts/build_submission.sh  
python scripts/audit_submission_package.py submit_package/pangu_weather.zip
```

10. 注意事项

① 各生成脚本为防止混用实验产物，对已存在的输出文件默认拒绝覆盖；请先归档旧文件。② 敏感度分析依赖 conf/config.yaml 配置的固定样本，不应使用隐藏评测数据做超参数选择。③ 每次重建后保存 Git 提交、代码 ZIP SHA256、模型 SHA256、运行日志和平台回执；只将完整证据链的成绩用作最终结论。④ 如 HIP 编译失败，先检查 /opt/dtk/bin/hipcc、/opt/dtk/lib、写权限和设备架构，不要通过修改数学常量绕过一致性检查。

本文档为纯文本说明，不包含图片。