

盘古气象大模型轻量化与推理优化说明

队伍：侍奉部

合规基线：pgw_lite_pruned_96 / model_fp16_alias_compact.pth

1. 合规基线

本提交以组委会盘古气象模型为教师，采用结构化剪枝和全 69 通道知识蒸馏。学生模型直接预测全部 69 个输出通道，不预测残差，不使用外置仿射、全局均值修正或测试样本间信息。官方计时代码块和 result.py 保持不变。

当前唯一锁定的合规平台基线：Total
90.7763；U（轻量化）36.6011；V（推理时长）17.9950；W（预测性能）36.1803。旧 90.8
成绩不作为合规基线或优化证据。

2. 固定模型结构

模型固定为 patch=[2,8,8]，embed_dim=96，num_heads=[3,6,6,3]，depth=[2,6,6,2]，window=[2,6,12]。宽度剪枝和 patch 放大减少参数与 token；蒸馏损失由真值 L1、教师 L1 与 layer1/layer2 特征损失组成，权重为 0.3/0.5/0.2。

3. 实际检查点表示

评分模型文件为 model_fp16_alias_compact.pth，在平台模型 ZIP 内仅改名为 model_fp16.pth。静态审计事实为：34.5139 MiB，250 tensors，FP16 31.8988 MiB，INT64 2.5312 MiB，实际 INT8 为 0，alias view savings 为 0。

旧 quantization 字段中的“62 个 INT8”是失效元数据，不能代替对 model_state_dict 实际 dtype、logical bytes 和 unique storage 的审计。

4. Stage 1 无损 U/V 候选

1) Region ID 预构建与 dense mask 释放：PANGU_P2_REGION_RELEASE 默认关闭。候选路径对精确 16 个 P2 attention 建立唯一 owner，要求恰好 8 个 shifted mask owner。每张 mask 必须只含 0/-100，并能通过 contiguous CUDA uint8 region IDs 逐矩阵精确重建。全部验证成功后才原子释放 dense mask，任何异常均在官方 timer 前报错，不 fallback。

2) earth_position_index 确定性省略：转换脚本只接受精确 pgw_lite_pruned_96，用 CPU 构造器逐 key torch.equal 验证后删除已证明的 INT64 index。检查点写入 key/shape/dtype/SHA256/bytes manifest；加载器仅允许已证明 alias 和 manifest index 缺失，unexpected key 必须为空。

3) HIP 库计时前预构建：PANGU_P2_PREBUILD_HIP

默认关闭。候选路径只在模型加载后执行源码指纹、编译、CDLL 加载和 ABI/config 验证，不调用模型 forward。提交包只保留 HIP 源码，不携带 .so。

4) 确定性 gzip-at-rest：固定 level 9、mtime=0、空 filename，重复压缩 SHA 必须一致，解压 SHA 必须等于原 PTH。仅在组委会书面确认 gzip stream 格式与计分口径后才会提交。

计时边界：上述预构建、重建、加载和解压都是模型初始化期间的单次操作，可位于计时前。每次推理都要执行的 attention、region-ID 消费和 HIP kernel 调用仍在 model(invar) 内并按官方边界计时。

5. A/B 晋级门

每项执行 5 个交错轮次，每轮 baseline/candidate 各 4 batches，共 10 个 subprocess。要求 4/4 输出文件集合、shape、dtype、SHA 和 np.array_equal 全部一致，NaN/Inf 为 0；官方 timer 代码块 SHA 与冻结基线一致。时延、P90、Current/Peak 显存及 paired bootstrap CI 都写入 logs/ 根目录 JSONL，任一硬门失败即拒绝候选。

6. 主要程序模块

inference.py：固定计时边界、严格检查点加载和 Stage 1 单次准备。

p2_tiled_attention.py / hip_earth_attention_tiled.py：P2 attention、region release 和 HIP 预构建。

scripts/elide_deterministic_indices.py：确定性 index 省略。

scripts/compress_checkpoint_gzip.py：gzip 候选生成和双次确定性验证。

scripts/probe_uv_runtime_sweep.py：交错 A/B、输出字节审计、统计与硬门。

7. 编译与静态验证

基础环境使用竞赛服务器预置的 Python、PyTorch/DTK 和 OneScience，不安装或替换 Python/系统包。可先执行：

```
python -m py_compile inference.py p2_tiled_attention.py hip_earth_attention_tiled.py
python -m unittest tests.test_p2_region_release_runtime tests.test_pruned96_state_load_contract
python module_test_scripts/test_probe_uv_artifacts.py
```

8. HIP 源码构建

仓库仅提交 hip_kernels/earth_attention_tiled_fwd.hip。hip_earth_attention_tiled.py 用源码、架构和参数指纹选择临时 build directory，通过 /opt/dtk/bin/hipcc 生成运行期 .so。预构建 helper 必须校验 Q tile=16、K tile=16、head dim=32、block threads=256、occupancy>=1 与非空 fingerprint。

```
/opt/dtk/bin/hipcc -O3 -std=c++17 -fPIC --shared -DPANGU_FULL_ROW_SCORE_STRIDE=144
-DPANGU_FULL_ROW_QK_TILE=16 hip_kernels/earth_attention_tiled_fwd.hip -Wl,-rpath,/opt/dtk/lib -o <fingerprint>.so
```

9. 生成 index-elision 候选

```
python scripts/elide_deterministic_indices.py --source data/checkpoints/model_fp16_alias_compact.pth --output
data/checkpoints/model_fp16_index_elided.pth
```

脚本会构造 CPU 模型、比较全部 index，验证 profile、dtype、shape、alias 和值，先写临时文件并回读校验，最后原子替换目标。输出文件已存在时拒绝覆盖。

10. 确定性 gzip 候选

```
python scripts/compress_checkpoint_gzip.py --source data/checkpoints/model_fp16_index_elided.pth --output
data/checkpoints/model_fp16_index_elided.pth.gz
```

脚本内部重复生成两份 gzip 并比较 SHA256，再解压回读验证原 PTH SHA256。在组委会确认前，该文件仅作本地候选，不进入平台提交。

11. 代码包构建与审计

```
PANGU_SUBMIT_DIR=/tmp/pangu_stage1_submit bash scripts/build_submission.sh
python scripts/audit_submission_package.py /tmp/pangu_stage1_submit/pangu_weather.zip
```

审计器对代码包执行精确白名单，对模型 ZIP 执行根成员、gzip magic、解码前后 SHA、实际 tensor dtype/bytes、INT8/scale/index/bias 数量与 manifest 一致性审计。

12. Region release 首轮服务器 A/B

```
python scripts/probe_uv_runtime_sweep.py --preset p2-region-release --fp16-checkpoint model_fp16_alias_compact.pth --repeat 5
--max-batches 4 --log-file logs/pruned96_region_release_90_7763_5x4.jsonl
```

JSONL 末行是 interleaved_ab_summary，其 stage1_hard_gate 必须 passed=true。Region 报告必须为 16 attentions、8 shifted owners、dense-after=0；Current allocated 下降至少为实测回收量的 0.9 倍，Peak 增加不超过 1 MiB，steady mean 回退不超过 0.5%，P90 回退不超过 1%。

13. Index checkpoint 交错 A/B

```
python scripts/probe_uv_runtime_sweep.py --preset baseline --fp16-checkpoint model_fp16_alias_compact.pth
--candidate-fp16-checkpoint model_fp16_index_elided.pth --repeat 5 --max-batches 4 --log-file
logs/pruned96_index_elision_90_7763_5x4.jsonl
```

Index/gzip 候选要求输出逐字节一致、显存不增加，steady mean 和 P90 回退均不超过 0.5%。只有在已接受 region 基线上仍独立通过时，才可组合。

14. HIP prebuild 独立 A/B

```
python scripts/probe_uv_runtime_sweep.py --preset p2-hip-prebuild --fp16-checkpoint model_fp16_alias_compact.pth --repeat 5
--max-batches 4 --log-file logs/pruned96_hip_prebuild_90_7763_5x4.jsonl
```

baseline/candidate 每次使用独立 fresh build directory。all-batch 平均加速必须至少 0.5%，paired bootstrap 95% CI 的 candidate-minus-baseline 上界必须小于 0，显存增加不超过 2 MiB。

15. 模型 ZIP 与提交顺序

模型 ZIP 必须只含根成员 model_fp16.pth；平台上的文件名只是对已验证检查点的改名。提交顺序为：Region release 单变量；在已接受 region 基线上叠加 index elision；HIP prebuild 仅在本地上过 0.5% 门后提交；gzip 仅在获得书面格式确认后最后提交。

每一步只有在 W=36.1803、目标分量严格提高、Total 高于当前 guardrail 时才成为新基线。非目标分量若下降，原样复测一次；连续下降即拒绝。未独立通过的候选不进入组合包。

16. 证据保存与 Stage 2

每次实验保存 Git commit、源码 SHA、代码 ZIP SHA、检查点 SHA、实际 tensor 审计、JSONL 和平台回执。Stage 1 冻结后，再修复 alias canonicalization 并研究真正 mixed INT8，优先评估 16 个、合计约 19.406 MiB 的 bias 表；随后才考虑真正生效的 QK32 和 LayerNorm-MLP 融合。所有有损方向只使用授权 train/validation 数据调参。

本文档为纯文本说明，不包含图片。